Infrastrutture convergenti ai

NetApp Solutions

NetApp
March 19, 2024

This PDF was generated from https://docs.netapp.com/it-it/netapp-solutions/ai/a400-thinksystem-introduction.html on March 19, 2024. Always check docs.netapp.com for the latest.

Sommario

Infrastrutture convergenti ai 1
Training sui modelli NetApp AFF A400 con Lenovo ThinkSystem SR670 V2 per ai e ML 1
NetApp ai con NVIDIA 13
NetApp EF-Series ai con NVIDIA 14
TR-4859: Implementazione della scalabilità dello spettro IBM con lo storage NetApp e-Series - Installazione e convalida 15
TR-4815: NetApp AFF A800 e Fujitsu Server PRIMERGY GX2570 M5 per i carichi di lavoro di training modello ai e ML 16

Infrastrutture convergenti ai

Training sui modelli NetApp AFF A400 con Lenovo ThinkSystem SR670 V2 per ai e ML

TR-4810: Training sul modello NetApp AFF A400 con Lenovo ThinkSystem SR670 V2 per ai e ML

Sathish Thyagarajan, David Arnette, NetApp Mircea Troaca, Lenovo

Questa soluzione presenta un'architettura di cluster midrange che utilizza lo storage NetApp e i server Lenovo ottimizzati per i carichi di lavoro di intelligenza artificiale (ai). È destinato alle piccole e medie imprese per le quali la maggior parte dei lavori di calcolo sono a nodo singolo (GPU singola o multipla) o distribuiti su alcuni nodi di calcolo. Questa soluzione si allinea con la maggior parte dei lavori di training ai giornalieri per molte aziende.

Il presente documento illustra il test e la convalida di una configurazione di calcolo e storage costituita da server Lenovo SR670V2 a otto GPU, un sistema storage NetApp AFF A400 di fascia media e uno switch di interconnessione da 100 GbE. Per misurare le performance, abbiamo utilizzato ResNet50 con il set di dati ImageNet, una dimensione batch di 408, mezza precisione, CUDA e cuDNN. Questa architettura offre una soluzione efficiente e conveniente per le piccole e medie imprese, iniziando con iniziative di ai che richiedono le funzionalità di livello Enterprise dello storage dei dati connesso al cloud di NetApp ONTAP.

Pubblico di riferimento

Il presente documento è destinato ai seguenti destinatari:

- Data scientist, data engineer, amministratori di dati e sviluppatori di sistemi ai
- Architetti aziendali che progettano soluzioni per lo sviluppo di modelli ai
- Data scientist e data engineer alla ricerca di metodi efficienti per raggiungere gli obiettivi di sviluppo del deep learning (DL) e dell'apprendimento automatico (ML)
- Business leader e decision maker IT/IT che desiderano ottenere il più rapido time-to-market possibile per le iniziative ai

Architettura della soluzione

Questa soluzione con server Lenovo ThinkSystem e NetApp ONTAP con storage AFF è progettata per gestire la formazione ai su grandi set di dati utilizzando la potenza di elaborazione delle GPU insieme alle CPU tradizionali. Questa convalida dimostra performance elevate e una gestione ottimale dei dati con un'architettura scale-out che utilizza uno, due o quattro server Lenovo SR670 V2 insieme a un singolo sistema storage NetApp AFF A400. La figura seguente fornisce una panoramica dell'architettura.

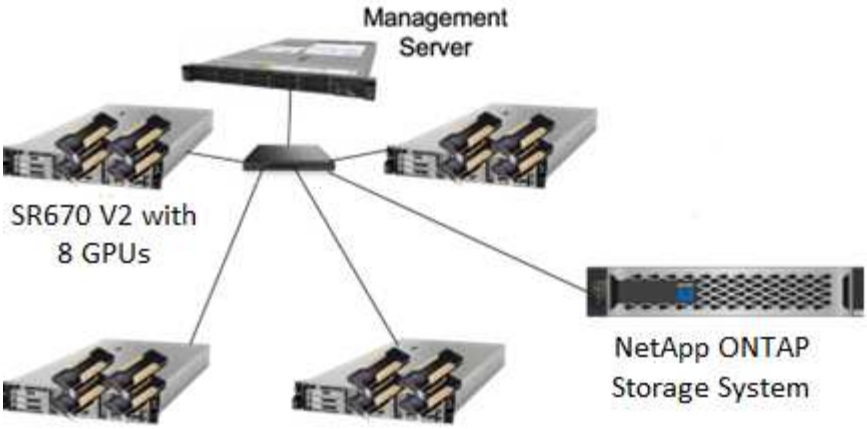

Questa soluzione NetApp e Lenovo offre i seguenti vantaggi principali:

- Performance altamente efficienti e convenienti quando si eseguono più lavori di formazione in parallelo
- Performance scalabili basate su diversi numeri di server Lenovo e diversi modelli di controller di storage NetApp
- Protezione dei dati efficace per soddisfare gli obiettivi RPO (Recovery Point Objective) e RTO (Recovery Time Objective) ridotti senza perdita di dati
- Gestione dei dati ottimizzata con snapshot e cloni per ottimizzare i flussi di lavoro di sviluppo

Panoramica della tecnologia

In questa sezione vengono presentati i principali componenti di questa soluzione in maggiore dettaglio.

Sistemi NetApp AFF

I sistemi storage NetApp AFF consentono alle aziende di soddisfare i requisiti di storage Enterprise con performance leader del settore, flessibilità superiore, integrazione nel cloud e gestione dei dati Best-in-class. Progettati appositamente per la tecnologia flash, i sistemi AFF aiutano ad accelerare, gestire e proteggere i dati business-critical.

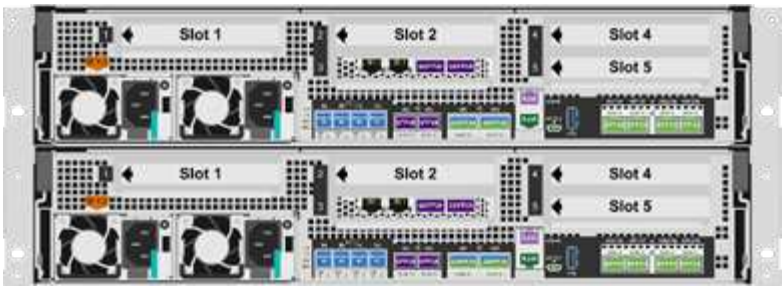

NetApp AFF A400 è un sistema di storage flash NVMe mid-range che include le seguenti funzionalità:

- Capacità effettiva massima: ~20 PB
- Scale-out massimo: 2-24 nodi (12 coppie ha)
- Supporto host FC da 25 GbE e 16 GB
- Connettività RDMA 100 GbE su RoCE (Converged Ethernet) agli shelf di storage di espansione NVMe
- Le porte RoCE da 100 GbE possono essere utilizzate per il collegamento alla rete host se gli shelf NVMe non sono collegati
- Shelf di storage per l'espansione della connettività SAS a 12 Gbps
- Disponibile in due configurazioni:
  - Ethernet: 4 porte Ethernet da 25 GB (SFP28)
  - Fibre Channel: 4 porte FC (SFP+) da 16 GB
- 100% lettura casuale 8 KB @0,4 ms 400.000 IOPS

Le funzionalità di NetApp AFF A250 per le implementazioni ai/ML entry-level includono:

- Capacità effettiva massima: 35 PB
- Scale-out massima: 2-24 nodi (12 coppie ha)
- 440.000 letture casuali IOPS @1 ms.
- Basato sull'ultima release di NetApp ONTAP ONTAP 9.8 o successiva
- Due porte Ethernet da 25 GB per ha e interconnessione cluster

NetApp offre anche altri sistemi storage, come AFF A800 e AFF A700, che offrono performance e scalabilità superiori per implementazioni ai/ML su larga scala.

NetApp ONTAP

ONTAP 9, l'ultima generazione di software per la gestione dello storage NetApp, consente alle aziende di modernizzare l'infrastruttura e passare a un data center predisposto per il cloud. Sfruttando le funzionalità di gestione dei dati leader del settore, ONTAP consente la gestione e la protezione dei dati con un singolo set di strumenti, indipendentemente dalla posizione dei dati. I dati possono anche essere spostati liberamente in qualsiasi punto: Edge, core o cloud. ONTAP 9 include numerose funzionalità che semplificano la gestione dei dati, accelerano e proteggono i dati critici e un'infrastruttura a prova di futuro su architetture di cloud ibrido.

Semplifica la gestione dei dati

La gestione dei dati è fondamentale per le operazioni IT aziendali, in modo da utilizzare le risorse appropriate per applicazioni e set di dati. ONTAP include le seguenti funzionalità per ottimizzare e semplificare le operazioni e ridurre il costo totale delle operazioni:

- **Compattazione dei dati inline e deduplica estesa.** la compattazione dei dati riduce lo spazio sprecato all'interno dei blocchi di storage e la deduplica aumenta significativamente la capacità effettiva. Ciò vale per i dati memorizzati localmente e per i dati a più livelli nel cloud.
- **Qualità del servizio (QoS) minima, massima e adattiva.** i controlli QoS granulari aiutano a mantenere i livelli di performance per le applicazioni critiche in ambienti altamente condivisi.
- **ONTAP FabricPool.** questa funzione esegue automaticamente il Tier dei dati cold su opzioni di cloud storage pubblico e privato, tra cui Amazon Web Services (AWS), Azure e storage a oggetti NetApp StorageGRID.

Accelera e proteggi i dati

ONTAP offre livelli superiori di performance e protezione dei dati ed estende queste funzionalità nei seguenti modi:

- **Prestazioni e latenza ridotta.** ONTAP offre il throughput più elevato possibile con la latenza più bassa possibile.
- **Protezione dei dati.** ONTAP offre funzionalità di protezione dei dati integrate con gestione comune su tutte le piattaforme.
- **Crittografia dei volumi NetApp.** ONTAP offre crittografia nativa a livello di volume con supporto per la gestione delle chiavi sia integrata che esterna.

Infrastruttura a prova di futuro

ONTAP 9 aiuta a soddisfare le esigenze di business esigenti e in continua evoluzione:

- **Scalabilità perfetta e operazioni senza interruzioni.** ONTAP supporta l'aggiunta senza interruzioni di capacità ai controller esistenti e ai cluster scale-out. I clienti possono eseguire l'upgrade alle tecnologie più recenti, come NVMe e 32GB FC, senza costose migrazioni dei dati o interruzioni.
- **Connessione al cloud.** ONTAP è il software di gestione dello storage più connesso al cloud, con opzioni per lo storage software-defined (ONTAP Select) e le istanze native del cloud (NetApp Cloud Volumes Service) in tutti i cloud pubblici.
- **Integrazione con applicazioni emergenti.** ONTAP offre servizi dati di livello Enterprise per piattaforme e applicazioni di prossima generazione come OpenStack, Hadoop e MongoDB utilizzando la stessa infrastruttura che supporta le applicazioni aziendali esistenti.

NetApp FlexGroup Volumes

I set di dati del training sono in genere una raccolta di potenzialmente miliardi di file. I file possono includere testo, audio, video e altre forme di dati non strutturati che devono essere memorizzati ed elaborati per essere letti in parallelo. Il sistema di storage deve memorizzare molti file di piccole dimensioni e leggerli in parallelo per l'i/o sequenziale e casuale

Un volume FlexGroup (la figura seguente) è un singolo namespace costituito da più volumi membri costitutivi gestiti e che agisce come un volume NetApp FlexVol per gli amministratori dello storage. I file in un volume FlexGroup vengono allocati a singoli volumi membri e non vengono sottoposti a striping tra volumi o nodi. Consentono le seguenti funzionalità:

- Fino a 20 petabyte di capacità e bassa latenza prevedibile per carichi di lavoro con metadati elevati
- Fino a 400 miliardi di file nello stesso spazio dei nomi
- Operazioni parallelizzate nei carichi di lavoro NAS tra CPU, nodi, aggregati e volumi FlexVol costitutivi

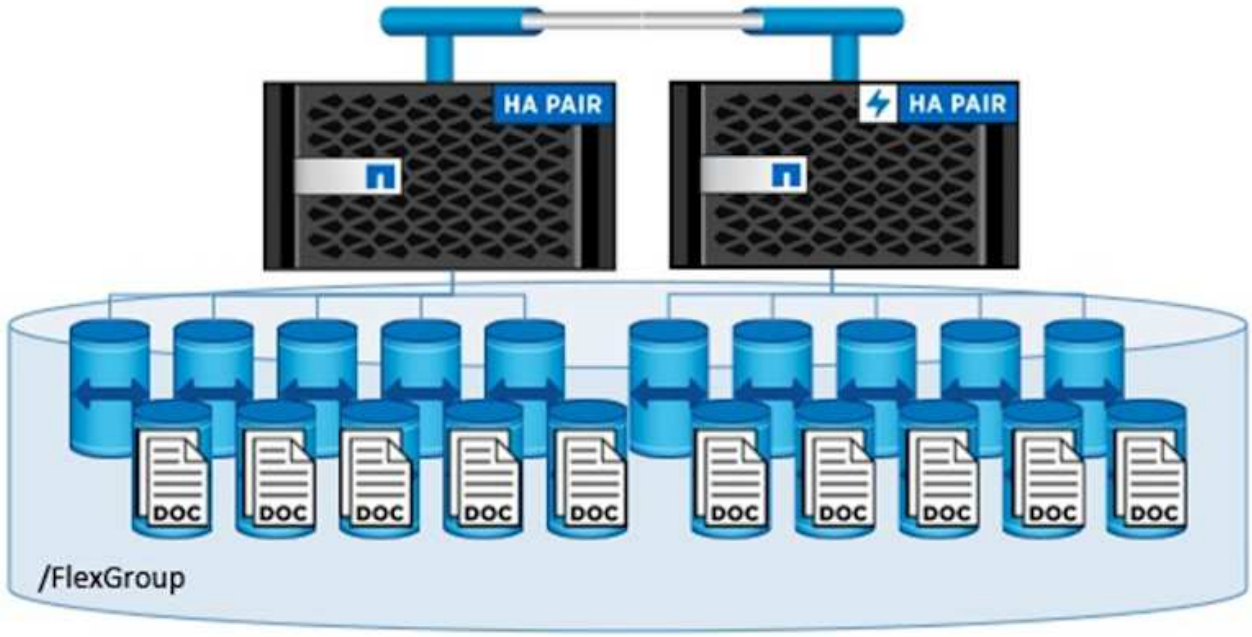

"

Portfolio Lenovo ThinkSystem

I server Lenovo ThinkSystem sono dotati di hardware, software e servizi innovativi che risolvono le sfide attuali dei clienti e offrono un approccio di progettazione modulare e evolutivo, adatto allo scopo, per affrontare le sfide del futuro. Questi server si basano su tecnologie Best-in-class e standard di settore, unite a innovazioni Lenovo differenziate per offrire la massima flessibilità possibile nei server x86.

I vantaggi principali dell'implementazione dei server Lenovo ThinkSystem includono:

- Design altamente scalabili e modulari in grado di crescere con il tuo business
- Resilienza leader del settore per risparmiare ore di costosi downtime non pianificati
- Tecnologie flash veloci per latenze inferiori, tempi di risposta più rapidi e gestione dei dati più intelligente in tempo reale

Nell'area dell'ai, Lenovo sta adottando un approccio pratico per aiutare le aziende a comprendere e adottare i vantaggi di ML e ai per i propri carichi di lavoro. I clienti Lenovo possono esplorare e valutare le offerte Lenovo ai nei Lenovo ai Innovation Center per comprendere appieno il valore del loro caso di utilizzo specifico. Per migliorare il time-to-value, questo approccio incentrato sul cliente offre ai clienti prove di concetto per piattaforme di sviluppo di soluzioni pronte all'uso e ottimizzate per l'ai.

Lenovo SR670 V2

Il server rack Lenovo ThinkSystem SR670 V2 offre performance ottimali per l'ai accelerato e l'HPC (high-performance computing). Con il supporto di un massimo di otto GPU, SR670 V2 è ideale per i requisiti di carico di lavoro intensivi a livello di calcolo di ML, DL e inferenza.

4x SXM GPUs with 8x 2.5-inch HS drives and 2x PCIe I/O slots

4x double-wide or 8x single-wide GPU slots and 2x PCIe I/O slots with 8x 2.5-inch or 4x 3.5-inch HS drives

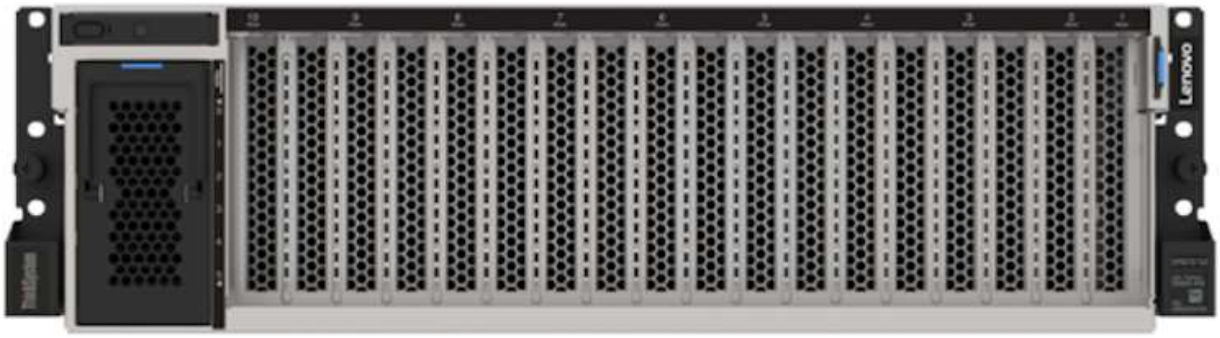

8x double-wide GPU slots with 6x EDSFF HS drives and 2x PCIe I/O slots

Con le più recenti CPU scalabili Intel Xeon che supportano GPU high-end (inclusa NVIDIA A100 80 GB PCIe 8x GPU), ThinkSystem SR670 V2 offre performance ottimizzate e accelerate per i carichi di lavoro ai e HPC.

Poiché più carichi di lavoro utilizzano le performance degli acceleratori, la domanda di densità GPU è aumentata. Settori come il retail, i servizi finanziari, l'energia e il settore sanitario stanno utilizzando le GPU per estrarre informazioni più approfondite e promuovere l'innovazione con LE tecniche ML, DL e Inference.

ThinkSystem SR670 V2 è una soluzione ottimizzata di livello Enterprise per l'implementazione di carichi di lavoro HPC e ai accelerati in produzione, massimizzando le performance del sistema mantenendo la densità del data center per i cluster di supercalcolo con piattaforme di prossima generazione.

Altre funzionalità includono:

- Supporto per i/o RDMA diretto GPU in cui gli adattatori di rete ad alta velocità sono collegati direttamente alle GPU per massimizzare le prestazioni i/O.

- Supporto dello storage diretto GPU in cui i dischi NVMe sono collegati direttamente alle GPU per massimizzare le performance dello storage.

MLPerf

MLPerf è la suite di benchmark leader del settore per la valutazione delle performance ai. In questa convalida, abbiamo utilizzato il benchmark di classificazione delle immagini con MXNet, uno dei framework ai più diffusi. Lo script di training MXNet_benchmarking è stato utilizzato per promuovere il training ai. Lo script contiene implementazioni di diversi modelli convenzionali ed è progettato per essere il più veloce possibile. Può essere eseguito su una singola macchina o in modalità distribuita su più host.

Piano di test

In questa convalida, abbiamo eseguito il training per il riconoscimento delle immagini come specificato da MLPerf v2.0. In particolare, abbiamo formato il modello ResNet v2.0 con il set di dati ImageNet fino a raggiungere una precisione del 76.1%. La metrica principale è il tempo necessario per raggiungere la precisione desiderata. Inoltre, segnaliamo la larghezza di banda del training in immagini al secondo per valutare meglio l'efficienza dello scale-out.

Il test case principale ha valutato più processi di training indipendenti (uno per nodo) in esecuzione simultanea. Simula il caso d'utilizzo principale, un sistema condiviso utilizzato da più data scientist. Il secondo caso di test ha valutato l'efficienza dello scale-out.

Risultati del test

La seguente tabella riassume i risultati di tutti i test eseguiti per questa soluzione.

Descrizione del test	Riepilogo dei risultati
Training sul riconoscimento delle immagini: Più processi simultanei	Performance altamente efficienti. Tutti i lavori venivano eseguiti alla massima velocità anche quando il cluster era completamente utilizzato. I sistemi storage NetApp hanno fornito performance di training paragonabili allo storage SSD locale, consentendo allo stesso tempo una facile condivisione dei dati tra server.
Training per il riconoscimento delle immagini: Scale-out	Altamente efficiente per un massimo di quattro nodi. A quel punto, la scalabilità orizzontale era meno efficiente ma ancora fattibile. L'utilizzo di una rete di calcolo ad alta velocità migliora la scalabilità. Il sistema storage NetApp ha fornito performance di training paragonabili allo storage SSD locale, consentendo al contempo una facile condivisione dei dati tra server.

Eseguire il test della configurazione

Questa sezione descrive le configurazioni testate, l'infrastruttura di rete, il server SR670 V2 e i dettagli sul provisioning dello storage NetApp.

Architettura della soluzione

Per questa convalida sono stati utilizzati i componenti della soluzione elencati nella tabella seguente.

Componenti della soluzione	Dettagli
Server Lenovo ThinkSystem	• Due server SR670 V2 ciascuno con otto schede GPU NVIDIA A100 da 80 GB • Ogni server contiene 2 CPU Intel Xeon Platinum 8360Y (28 core fisici) e 1 TB di RAM
Linux (Ubuntu – 20.04 con CUDA 11.8)	
Sistema storage NetApp AFF (coppia ha)	• Software NetApp ONTAP 9.10.1 • 24x 960 GB SSD • Protocollo NFS • 1 gruppo di interfacce (ifgrp) per controller, con quattro indirizzi IP logici per i mount point

In questa convalida, abbiamo utilizzato ResNet v2.0 con il set di base ImageNet come specificato da MLPerf v2.0. Il set di dati viene memorizzato in un sistema storage NetApp AFF con protocollo NFS. Gli SR670 sono stati collegati al sistema di storage NetApp AFF A400 tramite uno switch 100GbE.

ImageNet è un set di dati di immagini utilizzato di frequente. Contiene quasi 1.3 milioni di immagini per una dimensione totale di 144 GB. La dimensione media dell'immagine è di 108 KB.

La seguente figura illustra la topologia di rete della configurazione testata.

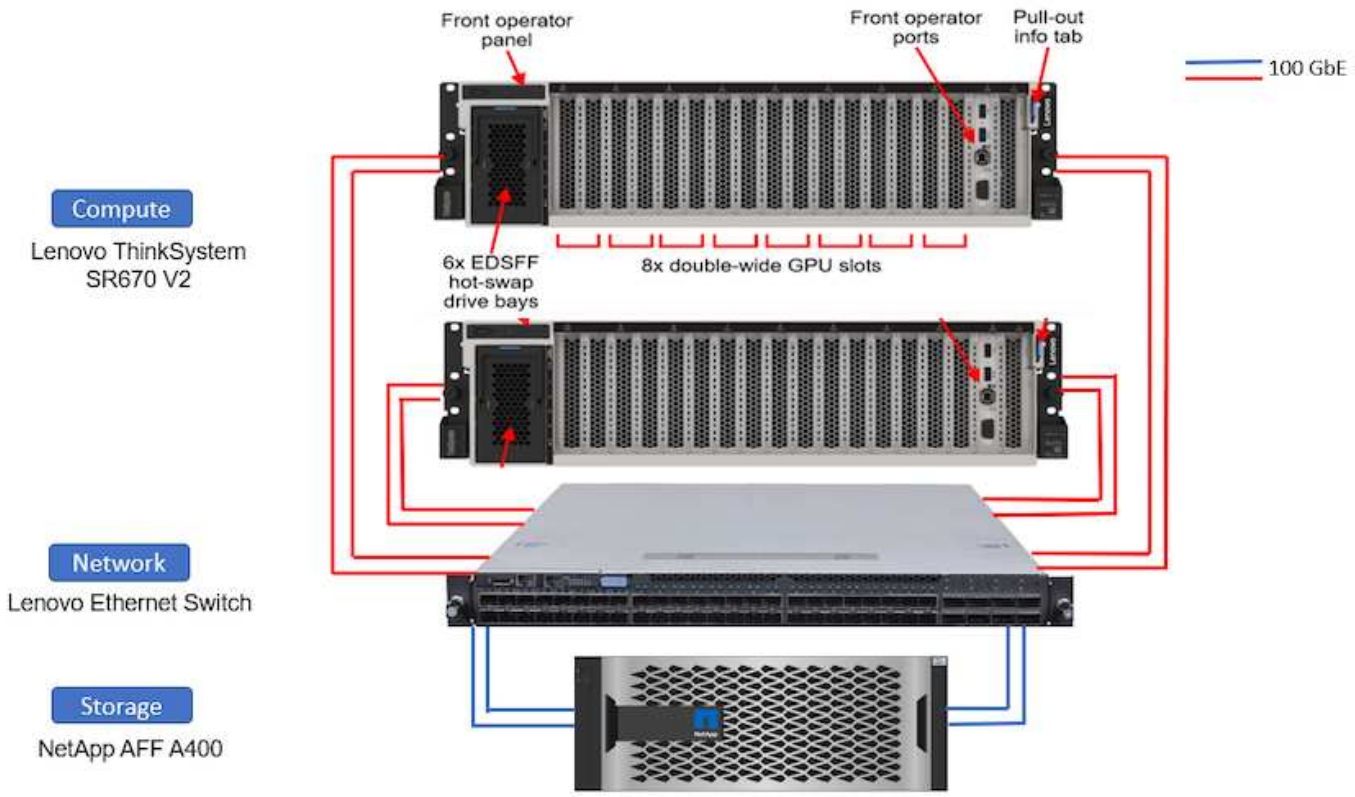

Controller dello storage

La seguente tabella elenca la configurazione dello storage.

Controller	Aggregato	Volume FlexGroup	Dimensione dell'aggregato	Dimensione del volume	Punto di montaggio del sistema operativo
Controller 1	Aggr1	/a400-100g	9,9 TB	19 TB	/a400-100g
Controller 2	Aggr2	/a400-100g	9,9 TB		/a400-100g

La cartella /a400-100g contiene il set di dati utilizzato per la convalida ResNet.

Procedura di test e risultati dettagliati

Questa sezione descrive i risultati dettagliati della procedura di test.

Training per il riconoscimento delle immagini con ResNet in ONTAP

Abbiamo eseguito il benchmark ResNet50 con uno e due server SR670 V2. Questo test ha utilizzato il container NGC MXNet 22.04-py3 per eseguire il training.

In questa convalida abbiamo utilizzato la seguente procedura di test:

1. Abbiamo cancellato la cache dell'host prima di eseguire lo script per assicurarsi che i dati non fossero già memorizzati nella cache:

   ```
   sync ; sudo /sbin/sysctl vm.drop_caches=3
   ```

2. Abbiamo eseguito lo script di benchmark con il set di dati ImageNet nello storage server (storage SSD locale) e nel sistema di storage NetApp AFF.
3. Abbiamo validato le performance dello storage locale e di rete utilizzando `dd` comando.
4. Per l'esecuzione a nodo singolo, è stato utilizzato il seguente comando:

```
python train_imagenet.py --gpus 0,1,2,3,4,5,6,7 --batch-size 408 --kv
-store horovod --lr 10.5 --mom 0.9 --lr-step-epochs pow2 --lars-eta
0.001 --label-smoothing 0.1 --wd 5.0e-05 --warmup-epochs 2 --eval-period
4 --eval-offset 2 --optimizer sgdwfastlars --network resnet-v1b-stats-fl
--num-layers 50 --num-epochs 37 --accuracy-threshold 0.759 --seed 27081
--dtype float16 --disp-batches 20 --image-shape 4,224,224 --fuse-bn-relu
1 --fuse-bn-add-relu 1 --bn-group 1 --min-random-area 0.05 --max-random
-area 1.0 --conv-algo 1 --force-tensor-core 1 --input-layout NHWC --conv
-layout NHWC --batchnorm-layout NHWC --pooling-layout NHWC --batchnorm
-mom 0.9 --batchnorm-eps 1e-5 --data-train /data/train.rec --data-train
-idx /data/train.idx --data-val /data/val.rec --data-val-idx
/data/val.idx --dali-dont-use-mmap 0 --dali-hw-decoder-load 0 --dali
-prefetch-queue 5 --dali-nvjpeg-memory-padding 256 --input-batch
-multiplier 1 --dali- threads 6 --dali-cache-size 0 --dali-roi-decode 1
--dali-preallocate-width 5980 --dali-preallocate-height 6430 --dali-tmp
-buffer-hint 355568328 --dali-decoder-buffer-hint 1315942 --dali-crop
-buffer-hint 165581 --dali-normalize-buffer-hint 441549 --profile 0
--e2e-cuda-graphs 0 --use-dali
```

5. Per le esecuzioni distribuite, abbiamo utilizzato il modello di parallelizzazione del server dei parametri. Abbiamo utilizzato due server di parametri per nodo e abbiamo impostato il numero di epoch in modo che sia uguale a quello dell'esecuzione a nodo singolo. Abbiamo fatto questo perché la formazione distribuita spesso richiede più epoche a causa della sincronizzazione imperfetta tra i processi. Il diverso numero di epoche può alterare i confronti tra casi a nodo singolo e distribuiti.

Velocità di lettura dei dati: Storage locale o di rete

La velocità di lettura è stata testata utilizzando `dd` Su uno dei file per il dataset ImageNet. Nello specifico, abbiamo eseguito i seguenti comandi per i dati locali e di rete:

```
sync ; sudo /sbin/sysctl vm.drop_caches=3dd if=/a400-100g/netapp-
ra/resnet/data/preprocessed_data/train.rec of=/dev/null bs=512k
count=2048Results (average of 5 runs):
Local storage: 1.7 GB/s Network storage: 1.5 GB/s.
```

Entrambi i valori sono simili, a dimostrazione del fatto che lo storage di rete è in grado di fornire dati a una velocità simile allo storage locale.

Caso d'utilizzo condiviso: Processi multipli, indipendenti e simultanei

Questo test ha simulato il caso d'utilizzo previsto per questa soluzione: Training ai multi-job e multi-utente. Ogni nodo ha eseguito il proprio training durante l'utilizzo dello storage di rete condiviso. I risultati vengono visualizzati nella seguente figura, che mostra che il caso della soluzione ha fornito prestazioni eccellenti con tutti i lavori eseguiti essenzialmente alla stessa velocità dei singoli lavori. Il throughput totale è stato scalato in modo lineare con il numero di nodi.

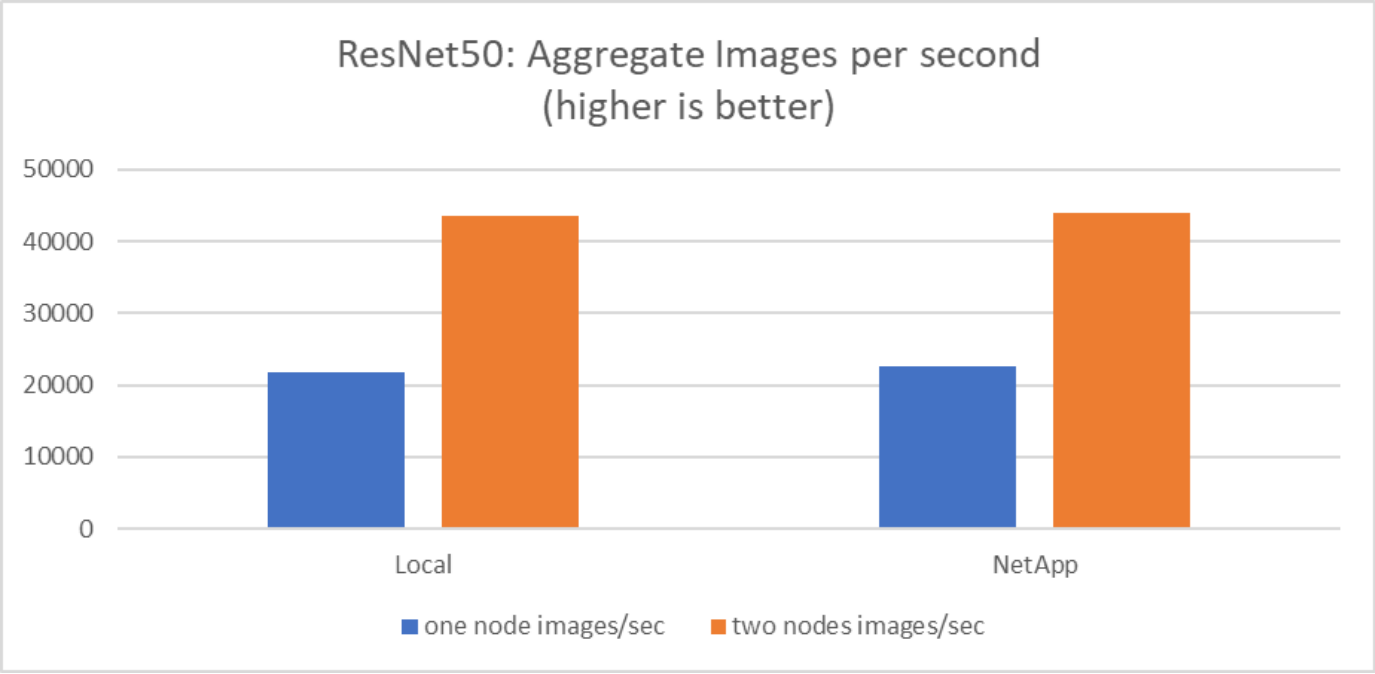

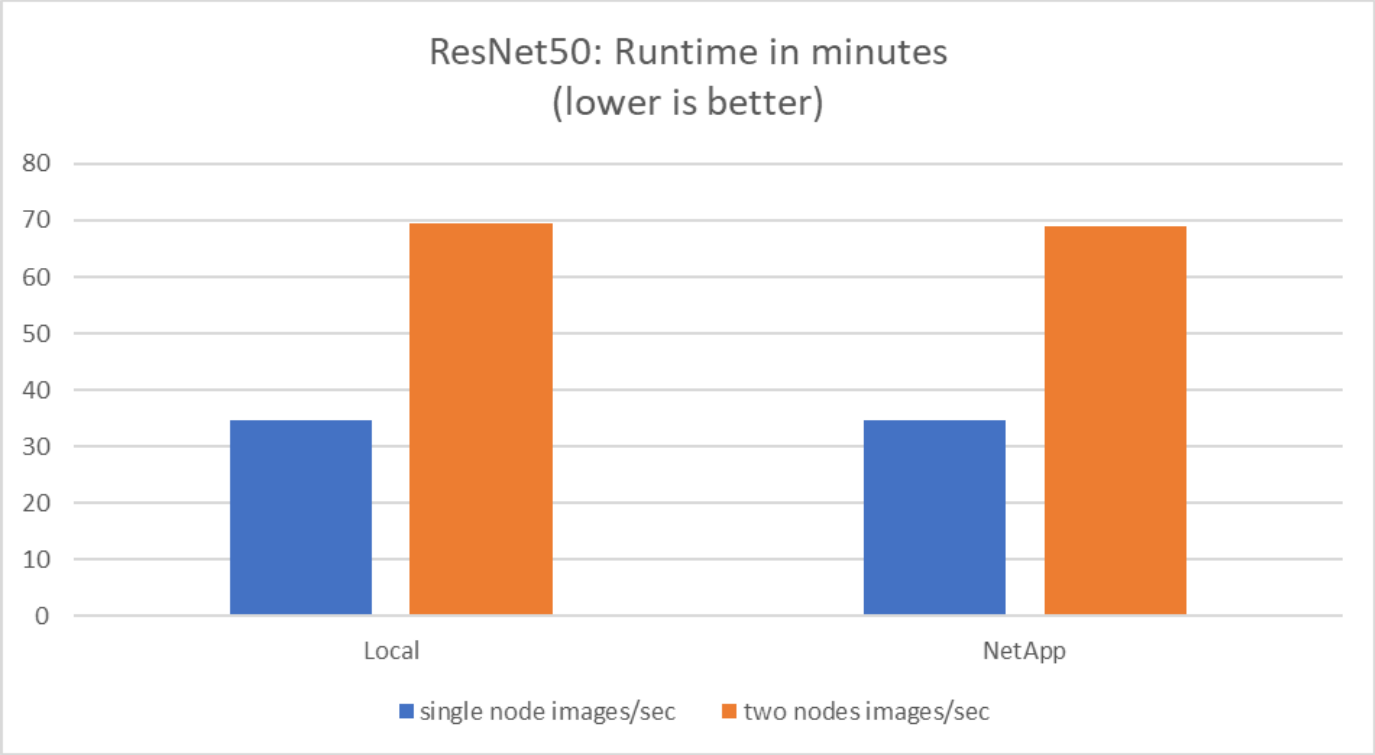

Questi grafici mostrano il runtime in pochi minuti e le immagini aggregate al secondo per i nodi di calcolo che utilizzavano otto GPU da ciascun server su reti client da 100 GbE, combinando sia il modello di training simultaneo che il modello di training singolo. Il tempo di esecuzione medio per il modello di training è stato di 35 minuti e 9 secondi. I singoli tempi di esecuzione erano di 34 minuti e 32 secondi, 36 minuti e 21 secondi, 34 minuti e 37 secondi, 35 minuti e 25 secondi, 34 minuti e 31 secondi. Le immagini medie al secondo per il modello di training erano 22,573, mentre le singole immagini al secondo erano 21,764, 23,438, 22,556, 22,564 e 22,547.

In base alla nostra convalida, un modello di training indipendente con data runtime NetApp è stato di 34 minuti e 54 secondi con 22,231 immagini/sec. Un modello di training indipendente con runtime dati locali (DAS) è stato di 34 minuti e 21 secondi con 22,102 immagini/sec. Durante queste operazioni, l'utilizzo medio della GPU

è stato del 96%, come osservato su nvidia-smi. Si noti che questa media include la fase di test, durante la quale le GPU non sono state utilizzate, mentre l'utilizzo della CPU è stato del 40% come misurato da mpstat. Ciò dimostra che la velocità di erogazione dei dati è sufficiente in ogni caso.

Modifiche dell'architettura

La configurazione utilizzata per questa convalida può essere regolata per adattarsi ad altri casi di utilizzo.

Regolazioni della CPU

Per questa convalida abbiamo utilizzato un processore Platinum Skylake Intel Xeon 8360Y, come raccomandato da Lenovo. Ci aspettiamo che l'equivalente CPU Cascade Lake, un processore Gold Intel Xeon 6330, offra performance simili perché questo carico di lavoro non è legato alla CPU.

Aumento della capacità dello storage

In base alle tue esigenze di capacità di storage, puoi aumentare lo storage condiviso (volume NFS) on-demand, a patto di disporre di shelf di dischi e modelli di controller aggiuntivi. È possibile eseguire questa operazione dall'interfaccia CLI o dall'interfaccia Web di NetApp del controller di storage come utente amministratore.

Conclusione

La soluzione NetApp e Lenovo validata qui è un'architettura scale-out flessibile ideale per l'ingresso nell'ai di medie imprese.

Lo storage NetApp offre le stesse performance o migliori dello storage SSD locale e offre i seguenti vantaggi a data scientist, data engineer e decision maker IT:

- Condivisione semplice dei dati tra sistemi ai, analytics e altri sistemi aziendali critici. Questa condivisione dei dati riduce l'overhead dell'infrastruttura, migliora le performance e ottimizza la gestione dei dati in tutta l'azienda.
- Calcolo e storage scalabili in maniera indipendente per ridurre al minimo i costi e migliorare l'utilizzo delle risorse.
- Workflow di sviluppo e implementazione ottimizzati grazie a snapshot e cloni integrati per spazi di lavoro degli utenti istantanei ed efficienti in termini di spazio, controllo delle versioni integrato e implementazione automatizzata.
- Protezione dei dati di livello Enterprise per disaster recovery e continuità del business.

Ringraziamenti

- Karthikeyan Nagalingam, Technical Marketing Engineer, NetApp
- Jarrett Upton, Admin, ai Lab Systems, Lenovo

Dove trovare ulteriori informazioni

Per ulteriori informazioni sulle informazioni descritte in questo documento, consultare i seguenti documenti e/o siti Web:

- Pagina del prodotto NetApp All Flash Array

"https://www.netapp.com/us/products/storage-systems/all-flash-array/aff-a-series.aspx"

- Pagina NetApp AFF A400

  "https://docs.netapp.com/us-en/ontap-systems/a400/index.html"

- Pagina del prodotto software per la gestione dei dati NetApp ONTAP

  "http://www.netapp.com/us/products/data-management-software/ontap.aspx"

- MLPerf

  "https://mlperf.org"

- Benchmark TensorFlow

  "https://github.com/tensorflow/benchmarks"

- NVIDIA SMI (nvidia-smi)

  "https://developer.nvidia.com/nvidia-system-management-interface"

NetApp ai con NVIDIA

Panoramica delle soluzioni di infrastruttura convergente ONTAP ai di NetApp e NVIDIA.

NetApp ONTAP ai con sistemi NVIDIA DGX A100

- "Guida alla progettazione"
- "Guida all'implementazione"

NetApp ONTAP ai con sistemi NVIDIA DGX A100 e switch Ethernet Mellanox Spectrum

- "Guida alla progettazione"
- "Guida all'implementazione"

NVA-1151-DESIGN: Guida alla progettazione dei sistemi NetApp ONTAP ai con NVIDIA DGX A100

David Arnette e Sung-Han Lin, NetApp

NVA-1151-DESIGN descrive un'architettura verificata NetApp per l'apprendimento automatico e i carichi di lavoro di intelligenza artificiale che utilizzano i sistemi storage NetApp AFF A800, i sistemi NVIDIA DGX A100 e gli switch di rete NVIDIA Mellanox. Include anche i risultati dei test di benchmark per l'architettura implementata.

"NVA-1151-DESIGN: Guida alla progettazione dei sistemi NetApp ONTAP ai con NVIDIA DGX A100"

NVA-1151-DEPLOY: NetApp ONTAP ai con sistemi NVIDIA DGX A100

David Arnette, NetApp

NVA-1151-DEPLOY include istruzioni per l'implementazione del sistema storage per un'architettura verificata NetApp (NVA) per i carichi di lavoro di apprendimento automatico (ML) e intelligenza artificiale (ai) utilizzando i sistemi storage NetApp AFF A800, i sistemi NVIDIA DGX A100 e gli switch di rete NVIDIA Mellanox. Include inoltre istruzioni per l'esecuzione dei test di benchmark di convalida al termine dell'implementazione.

"NVA-1151-DEPLOY: NetApp ONTAP ai con sistemi NVIDIA DGX A100"

NVA-1153-DESIGN: NetApp ONTAP ai con sistemi NVIDIA DGX A100 e switch Ethernet Mellanox Spectrum

David Arnette e Sung-Han Lin, NetApp

NVA-1153-DESIGN descrive un'architettura verificata NetApp per i carichi di lavoro di apprendimento automatico (ML) e intelligenza artificiale (ai) che utilizzano i sistemi storage NetApp AFF A800, i sistemi NVIDIA DGX A100 e gli switch Ethernet NVIDIA Mellanox Spectrum SN3700V 200 GB. Questo design è dotato di RDMA over Converged Ethernet (RoCE) per il fabric di interconnessione del cluster di calcolo per offrire ai clienti un'architettura completamente basata su ethernet per carichi di lavoro dalle performance elevate. Questo documento include anche i risultati dei test di benchmark per l'architettura implementata.

"NVA-1153-DESIGN: NetApp ONTAP ai con sistemi NVIDIA DGX A100 e switch Ethernet Mellanox Spectrum"

NVA-1153-DEPLOY: NetApp ONTAP ai con sistemi NVIDIA DGX A100 e switch Ethernet Mellanox Spectrum

David Arnette, NetApp

NVA-1153-DEPLOY include istruzioni di implementazione del sistema storage per un'architettura verificata NetApp per i carichi di lavoro di apprendimento automatico (ML) e intelligenza artificiale (ai) che utilizzano i sistemi storage NetApp AFF A800, i sistemi NVIDIA DGX A100 e gli switch Ethernet NVIDIA Mellanox Spectrum SN3700V da 200 GB. Include inoltre istruzioni per l'esecuzione dei test di benchmark di convalida al termine dell'implementazione.

"NVA-1153-DEPLOY: NetApp ONTAP ai con sistemi NVIDIA DGX A100 e switch Ethernet Mellanox Spectrum"

NetApp EF-Series ai con NVIDIA

Panoramica delle soluzioni di infrastruttura convergente EF-Series ai di NetApp e NVIDIA.

EF-Series ai con sistemi NVIDIA DGX A100 e BeeGFS

- "Guida alla progettazione"
- "Guida all'implementazione"
- "Guida all'implementazione di BeeGFS"

NVA-1156-DESIGN: NetApp EF-Series ai con sistemi NVIDIA DGX A100 e BeeGFS

Abdel Sadek, Tim Chau, Joe McCormick e David Arnette, NetApp

NVA-1156-DESIGN descrive un'architettura verificata di NetApp per i carichi di lavoro di machine learning (ML) e intelligenza artificiale (ai) che utilizzano i sistemi storage NetApp EF600 NVMe, il file system parallelo BeeGFS, i sistemi NVIDIA DGX A100 e gli switch IB NVIDIA Mellanox Quantum QM8700 a 200 Gbps. Questo design è dotato di InfiniBand (IB) a 200 Gbps per lo storage e il fabric di interconnessione del cluster di calcolo per offrire ai clienti un'architettura completamente basata su IB per carichi di lavoro dalle performance elevate. Questo documento include anche i risultati dei test di benchmark per l'architettura implementata.

"NVA-1156-DESIGN: NetApp EF-Series ai con sistemi NVIDIA DGX A100 e BeeGFS"

NVA-1156-DEPLOY: NetApp EF-Series ai con sistemi NVIDIA DGX A100 e BeeGFS

Abdel Sadek, Tim Chau, Joe McCormick e David Arnette, NetApp

Questo documento descrive un'architettura verificata di NetApp per i carichi di lavoro di apprendimento automatico (ML) e intelligenza artificiale (ai) che utilizzano i sistemi storage NetApp EF600 NVMe, il file system parallelo ThinkParQ BeeGFS, i sistemi NVIDIA DGX A100 e gli switch NVIDIA Mellanox Quantum QM8700 200Gbps InfiniBand (IB). Questo documento include anche istruzioni per l'esecuzione dei test di benchmark di convalida al termine dell'implementazione.

"NVA-1156-DEPLOY: NetApp EF-Series ai con sistemi NVIDIA DGX A100 e BeeGFS"

TR-4859: Implementazione della scalabilità dello spettro IBM con lo storage NetApp e-Series - Installazione e convalida

Chris Seirer, NetApp

TR-4859 descrive il processo di implementazione di una soluzione di file system completamente parallela basata sullo stack software Spectrum Scale di IBM. TR-4859 è progettato per fornire dettagli su come installare Spectrum Scale, convalidare l'infrastruttura e gestire la configurazione.

"TR-4859: Implementazione della scalabilità dello spettro IBM con lo storage NetApp e-Series - Installazione e convalida"

TR-4815: NetApp AFF A800 e Fujitsu Server PRIMERGY GX2570 M5 per i carichi di lavoro di training modello ai e ML

David Arnette, NetApp Takashi Oishi, Fujitsu

Questa soluzione si concentra su un’architettura scale-out per implementare sistemi di intelligenza artificiale con sistemi storage NetApp e server Fujitsu. La soluzione è stata validata con benchmark di training MLperf v0.6 utilizzando server Fujitsu GX2570 e un sistema storage NetApp AFF A800.

"TR-4815: NetApp AFF A800 e Fujitsu Server PRIMERGY GX2570 M5 per i carichi di lavoro di training modello ai e ML"

Informazioni sul copyright

Copyright © 2024 NetApp, Inc. Tutti i diritti riservati. Stampato negli Stati Uniti d'America. Nessuna porzione di questo documento soggetta a copyright può essere riprodotta in qualsiasi formato o mezzo (grafico, elettronico o meccanico, inclusi fotocopie, registrazione, nastri o storage in un sistema elettronico) senza previo consenso scritto da parte del detentore del copyright.

Il software derivato dal materiale sottoposto a copyright di NetApp è soggetto alla seguente licenza e dichiarazione di non responsabilità:

IL PRESENTE SOFTWARE VIENE FORNITO DA NETAPP "COSÌ COM'È" E SENZA QUALSIVOGLIA TIPO DI GARANZIA IMPLICITA O ESPRESSA FRA CUI, A TITOLO ESEMPLIFICATIVO E NON ESAUSTIVO, GARANZIE IMPLICITE DI COMMERCIABILITÀ E IDONEITÀ PER UNO SCOPO SPECIFICO, CHE VENGONO DECLINATE DAL PRESENTE DOCUMENTO. NETAPP NON VERRÀ CONSIDERATA RESPONSABILE IN ALCUN CASO PER QUALSIVOGLIA DANNO DIRETTO, INDIRETTO, ACCIDENTALE, SPECIALE, ESEMPLARE E CONSEQUENZIALE (COMPRESI, A TITOLO ESEMPLIFICATIVO E NON ESAUSTIVO, PROCUREMENT O SOSTITUZIONE DI MERCI O SERVIZI, IMPOSSIBILITÀ DI UTILIZZO O PERDITA DI DATI O PROFITTI OPPURE INTERRUZIONE DELL'ATTIVITÀ AZIENDALE) CAUSATO IN QUALSIVOGLIA MODO O IN RELAZIONE A QUALUNQUE TEORIA DI RESPONSABILITÀ, SIA ESSA CONTRATTUALE, RIGOROSA O DOVUTA A INSOLVENZA (COMPRESA LA NEGLIGENZA O ALTRO) INSORTA IN QUALSIASI MODO ATTRAVERSO L'UTILIZZO DEL PRESENTE SOFTWARE ANCHE IN PRESENZA DI UN PREAVVISO CIRCA L'EVENTUALITÀ DI QUESTO TIPO DI DANNI.

NetApp si riserva il diritto di modificare in qualsiasi momento qualunque prodotto descritto nel presente documento senza fornire alcun preavviso. NetApp non si assume alcuna responsabilità circa l'utilizzo dei prodotti o materiali descritti nel presente documento, con l'eccezione di quanto concordato espressamente e per iscritto da NetApp. L'utilizzo o l'acquisto del presente prodotto non comporta il rilascio di una licenza nell'ambito di un qualche diritto di brevetto, marchio commerciale o altro diritto di proprietà intellettuale di NetApp.

Il prodotto descritto in questa guida può essere protetto da uno o più brevetti degli Stati Uniti, esteri o in attesa di approvazione.

LEGENDA PER I DIRITTI SOTTOPOSTI A LIMITAZIONE: l'utilizzo, la duplicazione o la divulgazione da parte degli enti governativi sono soggetti alle limitazioni indicate nel sottoparagrafo (b)(3) della clausola Rights in Technical Data and Computer Software del DFARS 252.227-7013 (FEB 2014) e FAR 52.227-19 (DIC 2007).

I dati contenuti nel presente documento riguardano un articolo commerciale (secondo la definizione data in FAR 2.101) e sono di proprietà di NetApp, Inc. Tutti i dati tecnici e il software NetApp forniti secondo i termini del presente Contratto sono articoli aventi natura commerciale, sviluppati con finanziamenti esclusivamente privati. Il governo statunitense ha una licenza irrevocabile limitata, non esclusiva, non trasferibile, non cedibile, mondiale, per l'utilizzo dei Dati esclusivamente in connessione con e a supporto di un contratto governativo statunitense in base al quale i Dati sono distribuiti. Con la sola esclusione di quanto indicato nel presente documento, i Dati non possono essere utilizzati, divulgati, riprodotti, modificati, visualizzati o mostrati senza la previa approvazione scritta di NetApp, Inc. I diritti di licenza del governo degli Stati Uniti per il Dipartimento della Difesa sono limitati ai diritti identificati nella clausola DFARS 252.227-7015(b) (FEB 2014).

Informazioni sul marchio commerciale

NETAPP, il logo NETAPP e i marchi elencati alla pagina http://www.netapp.com/TM sono marchi di NetApp, Inc. Gli altri nomi di aziende e prodotti potrebbero essere marchi dei rispettivi proprietari.